

گزارش پروژه: تحلیل و خوشه‌بندی داده‌های شبکه اجتماعی

DataMinds (Zohre Nasiri Zarandi, Moein Zeynodini, Farhan Kian)

۱. مقدمه و هدف پروژه

هدف این پروژه، تحلیل داده‌های شبکه اجتماعی شامل تعداد لایکها، کامنت‌ها، و اشتراک‌گذاری‌ها و همچنین اطلاعات تکمیلی از جمله نرخ تعامل Engagement Rate و داده‌های قیمت دلار، با استفاده از روش‌های پیش‌پردازش داده، خوشه‌بندی (Clustering) و تحلیل آماری است. این تحلیل می‌تواند برای شناسایی الگوهای رفتاری کاربران و ارتباط آن با تغییرات اقتصادی (مانند نوسانات قیمت دلار* مورد استفاده قرار گیرد.

۲. بارگذاری کتابخانه‌ها و داده‌ها

- در ابتدای کد کتابخانه‌های مورد نیاز بارگذاری شده‌اند:
- سپس داده اصلی (Project1_Dataset.csv) خوانده شده و داده‌های منفی از ستون‌های likes, comments, و shares حذف شده‌اند.

۳. پیش‌پردازش داده‌ها

- حذف مقادیر منفی: برای اطمینان از معنادار بودن داده‌ها، رکوردهایی که مقدار لایک، کامنت یا اشتراک‌گذاری منفی داشتند حذف شدند.
- تبدیل تاریخ شمسی به میلادی: با استفاده از کتابخانه persiantools تاریخ‌ها از فرمت شمسی به میلادی تبدیل شدند تا امکان ادغام با داده‌های قیمت دلار فراهم شود.
- ادغام داده‌ها: داده شبکه اجتماعی با داده قیمت دلار بر اساس ستون مشترک date_gregorian ادغام شد.
- مدیریت فرمت تاریخ شمسی و ادغام داده‌های اینستاگرام با داده‌های قیمت دلار
- پر کردن مقادیر گم‌شده در ستون‌های مرتبط با دلار و شناسه اینفلوئنسرها
- تبدیل صحیح انواع داده‌ها (به‌ویژه ستون‌های change_amount و change_percent)
- ایجاد ویژگی‌های جدید مانند مجموع تعاملات، تعامل به ازای هر دنبال‌کننده و نوسان قیمت دلار
- کدگذاری متغیرهای دسته‌ای (مانند category, content_type, و influencer_id)
- مقیاس‌بندی ویژگی‌های عددی برای استفاده در الگوریتم‌های یادگیری ماشین
- مدیریت داده‌های پرت در نرخ تعامل (Engagement Rate)*، داده‌های پرت برای تحلیل بهتر حذف نشدند.

- ایجاد ویژگی‌های دودویی برای نرخ تعامل بالا و دنبال‌کنندگان زیاد

۴. مهندسی ویژگی‌ها

- نرخ تعامل: بر اساس لایک‌ها، کامنت‌ها، اشتراک‌گذاری‌ها و تعداد دنبال‌کننده‌ها محاسبه شد.
- کدگذاری ویژگی‌های متنی: با استفاده از Label Encoding به اعداد تبدیل شدند تا در الگوریتم‌ها قابل استفاده باشند.
- توضیح درباره اهمیت کامنت‌ها:
- کامنت‌ها نشان‌دهنده تعامل عمیق‌تر کاربر با محتوا هستند.
- حضور کامنت‌ها موجب افزایش دیده‌شدن پست‌ها در الگوریتم‌های شبکه‌های اجتماعی می‌شود.
- کامنت‌ها ایجاد مکالمه و تقویت جامعه کاربران را به دنبال دارند.
- توضیح درباره اهمیت اشتراک‌گذاری‌ها (*Shares):
- اشتراک‌گذاری‌ها نشانه تایید و ارزش‌گذاری محتوا توسط کاربران است.
- این کار موجب گسترش ارگانیک محتوا در شبکه می‌شود.
- اشتراک‌گذاری می‌تواند اثر ویروسی ایجاد کند و اعتبار اجتماعی محتوا را افزایش دهد.

۵. استانداردسازی داده‌ها

با استفاده از **StandardScaler** ویژگی‌های عددی مقیاس‌بندی شدند تا در فرآیند خوشه‌بندی، همه ویژگی‌ها وزن برابر داشته باشند:

۶. خوشه‌بندی داده‌ها

الگوریتم K-Means با تعداد خوشه ۳ ($k=3$) برای خوشه‌بندی داده‌ها به کار رفت. هدف از این مرحله، تقسیم داده‌ها به گروه‌هایی با رفتار مشابه در تعاملات و ویژگی‌های دیگر بود.

۷. تحلیل خوشه‌ها

پس از خوشه‌بندی، برای هر خوشه تحلیل آماری و بررسی همبستگی بین نرخ تعامل و تعداد دنبال‌کننده‌ها انجام شد.

Cluster	Features Summary	Suggested Name	Explanation (Persian)
0	- log_follower_count: ~0.98 (medium-high) - engagement_rate: slightly negative (-0.057) - weighted_engagement: slightly negative (-0.065) - likes/comments/shares: slightly negative - is_sponsored: ~0.60 (60% sponsored) - hashtag_count: near zero	Medium Followers, Moderate Sponsored	این خوشه شامل اینفلوئنسرهایی است که تعداد فالوئر متوسط تا نسبتاً بالا دارند، نرخ تعامل متوسط به پایین و تقریباً 60 درصد پست‌هایشان اسپانسر دار است.
1	- log_follower_count: 0.69 (کمتر از خوشه‌های دیگر) - engagement_rate: *0.27- خلیی پایین - likes/comments/shares: *0.24- خلیی پایین - is_sponsored: *0.64 - خلیی پایین - hashtag_count: *0.53 خلیی بالاتر از بقیه	Low Followers, Low Engagement, High Hashtags & Sponsored	این خوشه شامل اینفلوئنسرهایی با تعداد فالوئر کم، تعامل بسیار پایین، ولی استفاده زیاد از هشتگ‌ها و درصد زیادی پست اسپانسر دار دارند. معمولاً این‌ها کسانی هستند که تلاش می‌کنند با تبلیغات و هشتگ زیاد دیده شوند.
2	- log_follower_count: 0.99 (بالاترین) - engagement_rate: *0.08 مثبت - weighted_engagement: *0.09 مثبت - likes/comments/shares: مثبت - is_sponsored: 60% حدود - hashtag_count: نزدیک صفر	High Followers, High Engagement, Balanced Sponsored	این گروه اینفلوئنسرهای برتر با بیشترین تعداد فالوئر و نرخ تعامل بالاتر است که پست‌های اسپانسر دار متوسط دارند و هشتگ کمتری نسبت به خوشه 1 استفاده می‌کنند.

پس از خوشه‌بندی، برای هر خوشه تحلیل آماری انجام شد و مشخص شد:

خوشه ۲:

- بیشترین تعداد دنبال‌کننده، نرخ تعامل و تعامل وزن‌دار را دارد.
- بیشترین میانگین لایک و کامنت‌ها متعلق به این خوشه است.

خوشه ۱:

- کمترین تعداد دنبال‌کننده و نرخ تعامل را دارد.
- بیشترین استفاده از هشتگ‌ها در این خوشه مشاهده می‌شود که ممکن است تلاش برای جبران تعامل کمتر باشد.

خوشه ۰:

- در موقعیت متوسط قرار دارد و تعداد دنبال‌کننده و نرخ تعامل آن میانگین دو خوشه دیگر است.
- پارامترهای دیگر مانند اسپانسر بودن (is_sponsored) تقریباً در هر سه خوشه مشابه است.

نمودار زیر یک رادار چارت (Radar Chart) از پروفایل سه خوشه (Cluster 0، Cluster 1، Cluster 2) را نشان می‌دهد که حاصل خوشه‌بندی $k=3$ است.



تحلیل بر اساس ویژگی‌ها:

1. **log_follower_count**: خوشه 2 ، سبز بیشترین تعداد دنبال‌کننده را دارد، کمی بالاتر از خوشه 0 ، آبی و خوشه 1 ، نارنجی دنبال‌کننده‌های کمتری نسبت به بقیه دارد.
2. **engagement_rate** و **weighted_engagement**: خوشه 2 به وضوح نرخ تعامل بالاتری دارد و خوشه 1 کمترین نرخ تعامل را دارد.
3. **likes** و **comments**: خوشه 2 بیشترین لایک و کامنت را دریافت می‌کند و خوشه 1 بسیار پایین است، مخصوصاً در کامنت‌ها که تقریباً صفر است.
4. **shares**: خوشه 2 و 0 بالاتر از خوشه 1 هستند، ولی تفاوت شدید نیست.
5. **is_sponsored**: هر سه خوشه تقریباً یکسان هستند، احتمالاً به این معنی که اسپانسر بودن در همه گروه‌ها به نسبت مشابه رخ می‌دهد.
6. **hashtag_count**: خوشه 1 بیشترین استفاده از هشتگ را دارد و خوشه 0 کمترین تعداد هشتگ را استفاده می‌کند.

نتیجه گیری :

- خوشه ۲ بهترین عملکرد را دارد: بیشترین دنبال‌کننده، بیشترین نرخ تعامل و بیشترین تعامل وزن‌دار. این یعنی این دسته از اینفلوئنسرها، فالوورهای زیادی دارند و تعامل بیشتری هم با پست‌هایشان اتفاق می‌افتد.
- خوشه ۱ تعداد دنبال‌کننده کمتر و نرخ تعامل پایین‌تری دارد ولی بیشترین تعداد هشتگ را استفاده می‌کند. ممکن است این گروه برای جبران تعامل کمتر، از هشتک‌های بیشتری استفاده کنند.
- خوشه ۰ در میان دو خوشه دیگر است؛ تعداد دنبال‌کننده و تعامل متوسط دارد.

۸. نتایج آماری

همبستگی بین تعداد دنبال‌کننده و نرخ تعامل: محاسبات نشان داد که تقریباً هیچ رابطه‌ی خطی بین تعداد فالوورها و نرخ تعامل وجود ندارد. مقدار همبستگی بسیار نزدیک به صفر ، 0.0028 بود و مقدار $p\text{-value}$ برابر 0.9137 که نشان‌دهنده عدم وجود رابطه خطی معنادار بین این دو متغیر است. این یعنی تعداد دنبال‌کننده به تنهایی تعیین‌کننده نرخ تعامل نیست و عوامل دیگری مانند نوع محتوا یا زمان انتشار نقش مهم‌تری دارند.

این موضوع ممکن است نشان دهد که میزان تعامل لزوماً به تعداد فالوور وابسته نیست و عوامل دیگری مثل نوع محتوا، تعامل واقعی کاربران، یا زمان انتشار پست مهم‌تر هستند.

آزمون ANOVA برای مقایسه نرخ تعامل بین انواع محتوا، تصویر، ویدیو، چرخشی، متن: آزمون ANOVA تحلیل واریانس بررسی می‌کند که آیا میانگین متغیر عددی، در اینجا engagement rate بین چند گروه مختلف، در اینجا انواع محتوای text، carousel، video، image تفاوت معنادار آماری دارد یا نه.

در داده‌ها مشاهده شد، نوع محتوای منتشرشده، عکس، ویدیو، چرخشی یا متنی تأثیر مشخصی بر نرخ تعامل نداشته است. به بیان دیگر، نرخ تعامل بین این دسته‌ها تفاوت آماری قابل‌توجهی ندارد و ممکن است این تفاوت‌ها تصادفی باشند. نتایج نشان داد که تفاوت معنادار آماری بین میانگین نرخ تعامل این گروه‌ها وجود ندارد. یعنی نوع محتوای منتشر شده تأثیر مشخص و قابل توجهی بر نرخ تعامل نداشته است.

۹. جمع‌بندی

در این پروژه:

- داده‌های شبکه اجتماعی پاکسازی و به داده‌های قیمت دلار متصل شدند.
- ویژگی‌های کلیدی استخراج و مقیاس‌بندی شدند.
- الگوریتم خوشه‌بندی K-Means به خوبی داده‌ها را به سه گروه مجزا تقسیم کرد.
- تحلیل‌های آماری نشان داد که تعداد دنبال‌کننده‌ها به تنهایی معیار مناسبی برای پیش‌بینی نرخ تعامل نیست.
- نوع محتوا نیز تفاوت معناداری در نرخ تعامل ایجاد نکرده است.
- یافته‌ها می‌توانند در بهبود استراتژی‌های بازاریابی و مدیریت شبکه‌های اجتماعی کاربردی باشند.